

자동차 H/Shaft 이종품 검출을 위한 경량화 모델 성능 비교 및 최적화

[A Comparative Study on Lightweight Models and Structural Optimization
for H/Shaft Anomalous Part Detection in Smart Factories]

충북대학교 산업인공지능학과 2024254009 김다현


지도 교수 충북대학교 대학원 정보통신공학과 강현수

2025.12.12

프로젝트 개요

목표

스마트 공장 확산으로 실시간 AI 품질 검사의 중요성이 커졌으나,
산업 현장은 고성능 장비 도입에 제약이 있어 경량 모델의 필요성이 증가함
본 연구는 자동차 H/Shaft 이종품 검출을 위해 여러 경량 모델과 표준 모델을
비교하고, 최적 모델을 구조적으로 개선하여 성능을 향상함
최종적으로 제조 현장에 적용 가능한 경량 AI 품질 검사 모델과
실용적인 최적화 전략을 제시함



1 서론

연구 배경 / 연구 목적 /
연구 기대효과

2 배경 및 관련 연구

이론적 배경 / 딥러닝 기술 동향 /
경량화 모델 기술 동향 / 연구 차별성

3 연구 방법

시스템 개요 / 데이터 수집 및 전처리 /
이종품 검출 모델 선정


4 실험 결과

실험 환경 / 모델별 성능 비교 /
모델 최적화


5 결론

■ 연구 배경 및 필요성

- 스마트 팩토리 확산과 산업 자동화 확대에 따라 AI 기반 품질 검사 수요 증가 [1][2]
- 자동차 제조 공정은 다양한 센서와 고해상도 카메라를 통해 실시간으로 방대한 양의 데이터를 생성하며, 결함 탐지 및 품질 관리에 매우 중요하게 활용
- 엣지 컴퓨팅 시장의 성장으로 실시간 분석 필요성이 커지면서, 제한된 연산 환경에서도 동작 가능한 경량 모델의 중요성 높아짐





스마트 팩토리의 확산과 제조 자동화의 고도화



엣지 컴퓨팅 시장의 성장

■ 연구 목적

- 고성능 서버·클라우드 기반 AI 검사 시스템의 비용 및 보안 문제로 제조기업에 적용이 제한적
- 엣지 환경에서도 동작 가능한 경량 AI 모델의 필요성이 증가함
- 제조 공정에 적합한 경량 모델을 체계적으로 비교·선정한 연구는 부족
- 이에 따라 자동차 H/Shaft 공정의 이종품 검출을 위한 여러 경량화 이미지 분류 모델을 비교·분석하고, 공정에 적합한 최적 모델의 제안을 본 연구의 목표로 설정
- 정확도와 효율을 균형 있게 만족하는 경량화 모델의 실효성 검증 및 구조 개선 방향 제시를 주요 목적으로 함




스마트 팩토리 인식 조사

■ 기존 연구의 한계 및 본 연구 차별성



기존 연구는 GPU 기반
대용량 모델 위주로 엣지
환경 실시간 적용 어려움



경량 모델 적용을 통해 고성능
GPU 없이도 실시간 검사 및
비용 절감 가능



특정 모델·데이터셋 한정된
실험만 많고 비교 성능 지표
부족




H/Shaft 공정 경량화 실험을
통해 비교 성능 지표 구축 및
경량 모델 설계 제안

■ H/Shaft 이종품 검출 시스템 개요

■ 목표

H/Shaft 부품 이종품 검출용 딥러닝 이미지 분류 일반 CNN 모델과 경량화 모델 성능 비교

효율적인 균형의 성능을 보인 모델을 선택 후 추가적으로 경량화 적용하여 최적의 경량화—성능 모델 도출




이종품 검출 시스템 개요


■ 데이터 수집 및 전처리

■ 데이터 수집

H/Shaft 공정 나사의 상부 이미지로 나사의 산 수와 각도에 따라 4가지로 분류
4개 클래스로 구성된 비정형 이미지 데이터셋 「27산 30도, 27산 45도, 28산, 31산」



27산 30도



27산 45도



28산



31산

나사 이미지

■ 데이터 수집 및 전처리

항목	Train 데이터	Test 데이터
데이터 종류	비정형 데이터 (이미지)	비정형 데이터 (이미지)
클래스 수	4개	4개
클래스별 분포		
27산 30도	33,431장	27,894장
27산 45도	13,255장	5,472장
28산	60,939장	22,282장
31산	6,592장	1,144장

■ 데이터 수집

- 데이터셋: 114,217장 학습 / 56,792장 평가
- PLC로 이미지 클래스 자동 라벨링 및 클래스별 폴더 구성
- 클래스 불균형 문제 존재

■ 데이터 전처리

- Albumentations 라이브러리 사용 → 고속·효율적 이미지 변환
- 클래스별 가중치 적용 → 불균형 문제 완화

■ 이종품 검출 모델 선정

- 기본 CNN 모델 (Traditional CNN)
 - ResNet50 : Residual Block을 활용한 깊은 구조로, 기울기 소실 문제를 해결해 매우 안정적인 학습 가능
 - VGG16: 단순 규칙적 구조, Feature Extractor로 안정적, 해석 용이
- 경량화 모델 (Lightweight CNN)
 - DenseNet121 : Dense Connection, 특징 재사용, 적은 파라미터, 높은 정확도
 - MobileViT-S : CNN + ViT 하이브리드, 글로벌 컨텍스트 학습 가능, 엣지 환경 적합
 - MobileNetV2 : Inverted Residual + Depthwise Separable Convolution, 연산 효율·빠른 추론 속도
 - EfficientNet-B0 : NAS 기반, Compound Scaling(폭·깊이·해상도 균형), 작은 모델 크기에도 높은 정확도

■ 실험 환경

✓ 학습 환경

분류	항목	상세 사양
하드웨어	GPU	NVIDIA RTX 4090 (VRAM 24G B)
	CPU	Intel Core i9-13900K
	RAM	64GB
소프트웨어	운영체제 (OS)	Windows 11 Pro (64bit)
	프로그래밍 언어	Python 3.10
	딥러닝 프레임워크	PyTorch 2.2.0
	병렬 처리 API	CUDA 12.1

■ 실험 환경

✓ 모델 학습용 하이퍼파라미터

항목	값
Optimizer	Adam
Learning Rate	0.001
Batch Size	32
Epochs	10
Loss Function	CrossEntropyLoss

✓ 모델 성능 평가용 파라미터

지표 (Metric)	분류	단위	판단 기준
정확도	성능	%	높을수록 우수
파라미터 수	효율성	M	적을수록 우수
FLOPs	효율성	GFLOPs	적을수록 우수
모델 크기	효율성	MB	작을수록 우수


■ 기본 및 경량화 모델 성능 비교

✓ 모델별 성능 비교

- 목적 : H/Shaft 부품 이종품 검출용 6개 모델 성능 비교평가
- 기준: 정확도, FLOPs, 모델 크기, 파라미터 수
- 결과: 기존 CNN 모델과 경량화 모델의 성능 차이, 연산 효율성, 실시간 적용 가능성 확인


모델이름	모델 종류	Params (M)	Model Size (MB)	FLOPs (G)	Accuracy(%)
VGG16	기본	134.28	512.24	15.52	92.47
ResNet50	기본	23.52	90.01	4.13	99.94
DenseNet121	경량화	6.96	27.13	2.90	99.76
MobileViT-S	경량화	4.94	19.01	1.24	99.74
EfficientNet-B0	경량화	4.01	15.59	0.39	99.46
MobileNetV2	경량화	2.23	8.74	0.32	99.54

- 기본 및 경량화 모델 성능 비교
 - ✓ 모델 혼동행렬(Confusion Matrix)
 - 경량화 모델 Confusion Matrix




- 경량화 모델 Confusion Matrix에서는 대부분의 모델이 오분류가 적어 안정적인 분류 성능 확보

- 기본 및 경량화 모델 성능 비교
 - ✓ 모델 혼동행렬(Confusion Matrix)
 - 기본 모델 Confusion Matrix



ResNet50




VGG16

- ResNet50은 오분류가 적어 정확도가 높음
- VGG16에서는 상대적으로 많은 오분류가 발생


■ 기본 및 경량화 모델 성능 비교

✓ 모델 성능 및 효율성 비교 결과


■ Bar Chart



모델별 정확도 비교



모델별 연산량 비교




모델별 파라미터 수 비교

- 모델 정확도 비교 차트에서는 대부분의 모델이 99% 이상의 높은 성능을 기록
- MobileViT-S, MobileNetV2는 모델 파라미터와 크기가 가장 작으면서 높은 정확도를 가진 균형 잡힌 모델

■ 기본 및 경량화 모델 성능 비교

✓ 모델 성능 및 효율성 비교 결과


■ Bubble Chart



모델별 FLOPs-정확도 관계 및 모델 크기 비교(Bubble Chart)

- 연산량(FLOPs) 대비 분류 정확도를 시각화한 버블 차트
- 버블의 크기는 모델 크기, 색상은 파라미터 수
- 경량 모델 중 MobileNetV2는 파라미터·FLOPs·모델 크기 최저, 정확도 0.9954로 성능 대비 효율성 압도적
- ➔ 최적의 기준 모델로 선정

■ 경량화 모델의 추가 최적화 및 성능 평가



- MobileNetV2 구조에서 최적 경량화 실행
 1. 세 가지 경량화 기법(Width Multiplier 축소, Depth 축소, Compact 설계) 비교
 2. Width Multiplier 파라미터 조정($\alpha = 1.0, 0.75, 0.5, 0.25$)을 수행하여 비교
 3. 모델의 연산량, 파라미터 수, 정확도를 종합적으로 비교·평가

■ 경량화 모델의 추가 최적화 및 성능 평가

✓ 경량화 모델별 성능 비교 및 혼동행렬(Confusion Matrix)

- 1. 세 가지 경량화 기법(Width Multiplier 축소, Depth 축소, Compact 설계) 비교

모델 유형	Params (M)	Size (MB)	FLOPs (G)	Accuracy (%)
MobileNetV2	2.23	8.74	0.32	99.54
Depth 축소 모델	1.02	4.07	0.26	98.99
Width 축소 모델	0.69	2.82	0.11	96.36
Compact 모델 (Width + Depth)	0.28	1.19	0.09	93.11

- Width 축소, Compact 모델은 파라미터 수·FLOPs를 크게 감소시킴
- 경량화 + 성능에 있어 채널 축소보다 깊이 축소가 더 효과적
- 네트워크 깊이를 줄이는 방식이 연산 효율성과 성능 간 균형을 잘 유지함을 보여줌

■ 경량화 모델의 추가 최적화 및 성능 평가

✓ 경량화 모델별 성능 비교 및 혼동행렬(Confusion Matrix)

- 2. Width Multiplier 파라미터 조정 ($\alpha = 1.0 / 0.75 / 0.5 / 0.25$) 비교

모델명 (Width Multiplier α)	Params (M)	Size (MB)	FLOPs (G)	Accuracy (%)
$\alpha = 1.0$	2.23	8.74	0.32	99.25
$\alpha = 0.75$	1.36	5.40	0.22	98.39
$\alpha = 0.5$	0.69	2.82	0.11	91.07
$\alpha = 0.25$	0.24	1.08	0.04	77.57


✓ α 감소에 따른 모델 경량화 효과

- Width Multiplier 파라미터 α 를 줄일수록 파라미터 수는 최대 90% 감소($\alpha=1.0 \rightarrow \alpha=0.25$)
- 모델 크기는 약 1MB 수준까지 감소했으며, FLOPs 또한 0.32G $\rightarrow$ 0.04G 로 대폭 감소

■ 경량화 모델의 추가 최적화 및 성능 평가

✓ 경량화 모델별 성능 비교 및 혼동행렬(Confusion Matrix)

■ 2. Width Multiplier 파라미터 조정 모델 α 에 따른 정확도 추이 그래프



Accuracy vs Width Multiplier (α) 그래프

- α 가 1.0 $\rightarrow$ 0.25으로 감소할수록 정확도가 점진적 하락하는 것을 시각적으로 확인 가능
- $\alpha=0.75$ 까지는 상대적으로 안정적, $\alpha=0.5$ 이하부터 급격한 저하
- 채널 수 감소 = 특징 표현력 감소 $\rightarrow$ 분류 성능 하락
- 경량화 수준에 따라 정확도가 민감하게 변화함을 정량적으로 확인

■ 경량화 모델의 추가 최적화 및 성능 평가

✓ 경량화 모델별 성능 비교 및 혼동행렬(Confusion Matrix)

■ 3. MobileNetV2 기반 경량화 기법 최종 성능 비교 (정확도 순서)

모델 이름	Params (M)	Size (MB)	FLOPs (G)	Accuracy (%)
$\alpha = 1.0$	2.23	8.74	0.32	99.25
Depth 축소 모델	1.02	4.07	0.26	98.99
$\alpha = 0.75$	1.36	5.40	0.22	98.39
Width 축소 모델	0.69	2.82	0.11	96.36
Compact 모델	0.28	1.19	0.09	93.11
$\alpha = 0.5$	0.69	2.82	0.11	91.07
$\alpha = 0.25$	0.24	1.08	0.04	77.57

- Depth 축소 모델은 정확도 0.9899, FLOPs·파라미터 대폭 감소 → 가장 효율적인 모델
- Width 축소 시 α 가 작아질수록 정확도 점진적 하락, 모델 경량화 측면에서는 α 감소가 매우 효과적임을 확인
- $\alpha=0.25$ 모델은 경량화 극대화하지만 성능 크게 저하하여 Compact 모델이 초저자원 환경에서 활용 가능한 대안

1. 연구 목적 달성

- 산업용 실시간 비전 환경에서 정확도와 효율성을 동시에 충족하는 경량 이미지 분류 모델 개발
- 다양한 구조적·파라미터 경량화 기법을 적용

2. 경량화 연구의 산업적 의의



H/Shaft 공정이라는 희소한 제조 데이터셋을 활용한 실증적 연구



MobileNetV2 기반의 경량화 모델을 통한 현장 적용 가능성 도출



제조업 품질 관리의 디지털 전환을 위한 실용적 최적화 전략 제시

3. 향후 연구

- 향후 연구에서는 다양한 산업 데이터셋에서의 확장 실험과 함께 NAS, 지식 증류, 양자화 등 추가적 경량화 기법을 적용하여 실시간 산업용 모델의 성능을 더욱 고도화

감사합니다

Q & A

